

راهنمای نصب دستیار هوشمند

بازوی مواد تاندیش (بله) — نصب محلی با Ollama — بدون API ابری

۱. معرفی و محدودیت

و بازه‌ای، موجودی و مواد بحرانی، مواد مازاد، پیش‌بینی، پیشنهاد درخواست، فعالیت کاربران و مفاهیم PDF کامل تحلیل. است که فقط درباره گزارش‌ها و اعداد گزارش‌محور پاسخ می‌دهد: خلاصه مصرف ماهیانه، ورودی انبار، مصرف روزانه دستیار هوشمند یک گفتگوی محلی داخل ربات بله محدودیت‌های مهم:

مورد	توضیح
دامنه	موجودی، درخواست مواد، مدیریت کاربر و تنظیمات را انجام نمی‌دهد فقط گزارش‌ها — آپلود، ویرایش
اجرا	مدل روی همین سرور با Ollama (یا سازگار) — بدون API ابری
نقش‌ها	همه نقش‌ها به‌جز تکنسین
قطعی بودن	پیام «دستیار محلی در دسترس نیست...» نشان داده می‌شود اگر Ollama خاموش باشد ربات کرش نمی‌کند؛

۲. پیش‌نیاز سخت‌افزار و نرم‌افزار

مورد	پیشنهاد
سیستم‌عامل	لینوکس (Ubuntu/Debian یا سازگار)
Python	۳٫۱۰ یا بالاتر (برای خود ربات)
RAM	۴ گیگابایت برای qwen2.5:3b — با ۸ گیگابایت یا بیشتر راحت‌تر حداقل
CPU	چند هسته کافی است؛ GPU اختیاری
فضای دیسک	چند گیگابایت برای مدل (مدل ۳B حدود ۲ گیگابایت)
شبکه	نصب اولیه و ollama pull نیاز به اینترنت؛ پس از آن کار محلی است

مدل پیش‌فرض ربات: qwen2.5:3b. اگر RAM کم است از qwen2.5:1.5b استفاده کنید.

۳. نصب همراه ربات با install.sh

در ترمینال واقعی (TTY) داخل ریشه پروژه اجرا کنید:

```
cd special-materials-robot-project
```

```
bash install.sh
```

ویزارد فارسی می‌پرسد: «دستیار هوشمند را هم نصب کنم؟ (Y/n)» — پیش‌فرض بله (Enter یا Y).

با تأیید:

• در صورت نبود، Ollama نصب می‌شود

- مدل پیش فرض (qwen2.5:3b یا مقدار OLLAMA_MODEL) با ollama pull کشیده می‌شود
- متغیرهای *_OLLAMA در فایل env. نوشته یا به روز می‌شوند

پرچم‌های غیرتعاملی:

معنی	پرچم
بدون پرسش، Ollama + مدل + env. را نصب/تنظیم کن	--with-assistant
دستیار را رد کن (Ollama نصب نشود)	--no-assistant

```
bash install.sh --with-assistant --systemd --start
```

```
bash install.sh --no-assistant
```

۴. نصب دستی Ollama و مدل

اگر install.sh را با --no-assistant زده‌اید یا می‌خواهید دستی نصب کنید:

```
curl -fsSL https://ollama.com/install.sh | sh
```

اگر سرویس بالا نیست # ollama serve

```
ollama pull qwen2.5:3b
```

کم RAM مدل سبک‌تر برای # ollama pull qwen2.5:1.5b

سایر گزینه‌ها: llama3.2:3b , phi3:mini

۵. تنظیم env.

در ریشه پروژه (کنار main.py) این متغیرها را بگذارید:

```
OLLAMA_BASE_URL=http://127.0.0.1:11434
```

```
OLLAMA_MODEL=qwen2.5:3b
```

```
OLLAMA_TIMEOUT=60
```

- اگر این خطوط نباشند، همین مقادیر پیش فرض در کد استفاده می‌شوند.
- باید به سرویس محلی اشاره کند؛ به سرویس ابری وصل نکنید OLLAMA_BASE_URL
- نمونه کامل در فایل env.example آمده است.

۶. راه اندازی و تست

تأیید نصب مدل:

```
ollama list
```

تست API محلی با curl:

```
curl -s http://127.0.0.1:11434/api/tags
```

```
curl -s http://127.0.0.1:11434/api/chat -d '{"model": "qwen2.5:3b", "messages": [{"role": "user", "content": "hi"}], "stream": false}'
```

روشن کردن ریات:

```
source .venv/bin/activate
```

```
python main.py
```

```
# یا: bash install.sh --systemd --start
```

ربات و Ollama باید هم‌زمان روی همان ماشین در دسترس باشند.

۷. استفاده در بله

- (1) در بله به بازو /start بزنید.
 - (2) منوی «گزارش‌ها / تحلیل تاندیش» را باز کنید.
 - (3) دکمه « دستیار هوشمند» را بزنید.
 - (4) سؤال خود را درباره گزارش‌ها بنویسید.
 - (5) برای خروج: «پایان گفتگو» یا بازگشت به تحلیل / منوی اصلی.
- منو دسترسی ندارد. امنیت: هیچ درخواست LLM به ابر ارسال نمی‌شود؛ فقط HTTP محلی به Ollama روی سرور شما. نقش تکنسین به این

۸. رفع اشکال

مشکل	کار پیشنهادی
محلی در دسترس نیست؛ Ollama را روی سرور بررسی کنید.» پیام «دستیار	؛ پورت ollama serve:11434 یا ollama status OLLAMA_BASE_URL
مدل در ollama list نیست	ollama pull مطابق OLLAMA_MODEL
پاسخ خیلی کند	کوچک‌تر (1.5b)، افزایش RAM/CPU، OLLAMA_TIMEOUT بیشتر مدل
تکنسین دکمه را نمی‌بیند	طبق طراحی؛ نقش‌های دیگر را استفاده کنید
دو نمونه ربات با یک توکن	فقط یک polling؛ نمونه اضافه را خاموش کنید

لاگ ربات (systemd): journalctl -u nasoz-bot -f

۹. به‌روزرسانی

به‌روزرسانی کد ربات:

```
bash install.sh --update
```

به‌روزرسانی یا تعویض مدل:

```
ollama pull qwen2.5:3b
```

```
ollama pull qwen2.5:1.5b
```

سپس OLLAMA_MODEL را در env عوض کنید و ربات را restart کنید

```
sudo systemctl restart nasoz-bot
```

خلاصه امنیتی: دستیار هوشمند فقط گزارش‌محور است، روی سرور شما اجرا می‌شود، و به LLM ابری وابسته نیست.